



Actividad | #2 | Software, Personal y Procesos

Minería y Análisis de Datos

Ingeniería en Desarrollo de Software



TUTOR: JESSICA HERNANDEZ ROMERO

ALUMNO: ANWAR DAVID CARAVANTES PERAZA

FECHA: 08 DE JUNIO DE 2026

DESARROLLO

Software de Data Mining

En esta actividad se estuvo investigando sobre las tecnologías y herramientas que existen en el mercado de la Data Mining, con lo que procedimos a realizar la siguiente tabla:

Tecnología de minería de datos	¿Por qué propondría ese software?	¿Qué procesos de minería de datos puede realizar el software?
Splunk (Enterprise Security)	Es una plataforma líder para la indexación y minería de machine data distribuidos a nivel nacional. Su lenguaje SPL permite realizar correlaciones complejas y búsquedas masivas de patrones analíticos de forma casi instantánea	Ingesta masiva y normalización de datos no estructurados, detección de anomalías estadísticas mediante Machine Learning integrado, minería de texto en logs y modelado predictivo de comportamientos anómalos.
IBM QRadar SIEM	Es una herramienta de grado corporativo sumamente robusta para la centralización y análisis automatizado de flujos de información que destaca por su motor de correlación de eventos basado en reglas y su capacidad de consolidar billones de registros en alertas accionables.	Descubrimiento automático de activos de red, correlación avanzada de reglas de comportamiento, análisis predictivo de patrones de riesgo y minería de datos históricos para auditorías de cumplimiento.
Elastic Stack (ELK)	Funciona como una alternativa ágil y distribuida de código abierto para complementar el ecosistema	Procesamiento, filtrado y enriquecimiento de datos en crudo (Logstash), búsquedas indexadas de texto completo a

	analítico. Permite recolectar, transformar, almacenar y visualizar registros masivos en tiempo real a una fracción del costo de otras plataformas.	gran escala (Elasticsearch) y minería visual de patrones mediante paneles interactivos (Kibana).
--	--	--

¿Cuál es el mejor gestor de base de datos para este proyecto?

Lo mejor es implementar un ecosistema con PostgreSQL montado en un servidor VPS de Amazon Web Services dedicado de alta disponibilidad para un repositorio analítico centralizado (Data Warehouse Hospedado) y para el procesamiento masivo debe ir acoplado a un motor analítico en la nube simulando un Appliance físico DWA como Netezza o Teradata

Perfiles y Roles

En esta actividad utilizaremos Infinity Free y nos registramos

Ingeniero de Datos: Es el especialista enfocado en la infraestructura pura. Su tarea principal es construir y cuidar los flujos automatizados (pipelines) que jalen los registros de todos los servidores del país hacia el servidor VPS, garantizando además que la base de datos en PostgreSQL funcione de forma óptima.

Científico de Datos: Es la mente matemática del equipo. Se encarga de explotar el volumen masivo de información dentro de Splunk o QRadar, aplicando algoritmos estadísticos y

machine learning para encontrar patrones ocultos y predecir anomalías o riesgos operativos antes de que causen problemas a nivel nacional.

Analista de BI: El encargado final de los datos, es decir, la visualización. Este perfil traduce los números complejos en tableros de control interactivos o paneles visuales interactivos (dashboards) usando las interfaces de Splunk, facilitando el monitoreo en tiempo real.

Se está considerando contar con 1 especialista de cada perfil para este proyecto.

Proceso del Proyecto

Para este proyecto se estará utilizando la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining) que es un estándar internacional para los proyectos de Data Mining. Este proceso consta de 6 fases:

1. Entender el negocio - Se delimita qué problemas reales se quieren solucionar
2. Entender los datos - Se analiza la estructura de los datos
3. Preparar los datos - Se limpian, filtra y transforma toda la información cruda
4. Modelado - Se entrenan los modelos y se configuran las reglas de los modelos
5. Evaluación - Se evalúa que los patrones resuelvan los problemas del paso 1
6. Despliegue (Implantación) - Se habilita el proyecto y se habilitan los dashboards para el monitoreo de la información constante para la toma de decisiones

Cronograma de actividades

Se realiza el cronograma para las actividades del proyecto con los responsables y los tiempos por semana del proyecto con una duración proyectada de 3 meses (12 semanas)

Actividad / Subactividad	Responsable	S1	S2	S3	S4	S5	S6	S7	S8	S9	S10	S11	S12
1. ENTENDER EL NEGOCIO													
1.1 Alineación de objetivos nacionales	Todos												
1.2 Definición de casos de uso y KPIs	Todos												
2. ENTENDER LOS DATOS													
2.1 Mapeo de fuentes y auditoría de logs	Ing. Datos												
2.2 Pruebas de conexión con el VPS AWS	Ing. Datos												
3. PREPARAR LOS DATOS													
3.1 Diseño de scripts de limpieza y ETL	Ing. Datos												
3.2 Estructuración en PostgreSQL	Ing. Datos												
3.3 Normalización de eventos en el SIEM	Ing. Datos												
4. MODELADO ANALÍTICO													
4.1 Carga de datos históricos en memoria	Científico Datos												
4.2 Configuración de reglas de correlación	Científico Datos												
4.3 Entrenamiento de Machine Learning	Científico Datos												
5. EVALUACIÓN DE MODELOS													
5.1 Pruebas de estrés y falsos positivos	Científico Datos												
5.2 Ajuste fino y calibración final	Científico Datos												
6. DESPLIEGUE E IMPLANTACIÓN													
6.1 Diseño de paneles en Splunk	Analista BI												
6.2 Automatización y entrega a Juan	Analista BI												

Propuesta de Software y Motivo de Selección

Para la consolidación de la nueva área analítica a nivel nacional, se propone una arquitectura híbrida compuesta por Splunk (Enterprise Security) como plataforma central de minería y gestión analítica de eventos masivos (SIEM), acoplada a un entorno relacional robusto sobre PostgreSQL hospedado en una infraestructura elástica de Amazon Web Services (AWS).

Motivo de selección: La combinación de estas tecnologías responde directamente a la necesidad de procesar billones de registros de infraestructura distribuidos por todo el país sin incurrir en la compra de costosos equipos físicos (appliances locales). Splunk ofrece búsquedas casi instantáneas gracias a su lenguaje SPL, ideal para detectar patrones de riesgo en tiempo real, mientras que PostgreSQL en AWS garantiza un almacén de datos (Data Warehouse) centralizado, seguro, altamente disponible y de código abierto, reduciendo drásticamente los costos de licenciamiento corporativo.

Propuesta del Personal Necesario y Requisitos Operativos

Para llevar a cabo el proyecto de manera exitosa en el plazo proyectado de 3 meses, se requiere la contratación de un equipo técnico compacto y altamente especializado de **3 personas**, operando bajo los siguientes requisitos:

1 Ingeniero de Datos: Requisito indispensable para encargarse de la fase crítica de extracción, limpieza y normalización de datos (ETL) hacia el servidor VPS. Sin este perfil, el sistema carecería de información estructurada y fiable.

1 Científico de Datos: Requisito matemático enfocado en la fase analítica avanzada,

encargado de entrenar los algoritmos de machine learning y configurar la lógica de correlación para predecir incidentes operativos.

1 Analista de Inteligencia de Negocios: Requisito clave para la traducción de métricas complejas a un entorno ejecutivo, responsable de diseñar los paneles interactivos (dashboards) en tiempo real para el monitoreo y la toma de decisiones rápidas. Requisitos Tecnológicos
Mínimos: Acceso e infraestructura de red con los permisos necesarios para la extracción segura de logs de todos los servidores nacionales. Instancia VPS activa en AWS optimizada para alta disponibilidad de datos.

Ejecución Estratégica del Proyecto para Garantizar el Éxito

Para asegurar que la implementación sea exitosa y se adopte correctamente por la organización, la ejecución se llevará a cabo mediante un enfoque metodológico estricto basado en las siguientes pautas operativas:

Gobernanza y Alineación Inicial: El proyecto no iniciará desde la programación, sino desde el entendimiento del negocio, asegurando que las reglas y alertas analíticas que se configuren en Splunk resuelvan problemáticas operativas reales y generen KPIs de valor para la mesa directiva.

Aseguramiento de Calidad del Dato: Se dedicarán las primeras semanas exclusivamente a auditar las fuentes de información a nivel nacional y automatizar scripts de limpieza en PostgreSQL, evitando el clásico error de alimentar los algoritmos analíticos con datos masivos corruptos o incompletos.

Monitoreo Proactivo sin Saturación (Control de Falsos Positivos): Antes del despliegue en producción, se implementará una fase obligatoria de evaluación y calibración estadística de los modelos matemáticos, reduciendo las falsas alarmas que puedan entorpecer el día a día operativo del equipo.

Transferencia de Conocimiento y Visualización Ejecutiva: El éxito final radicará en la entrega de tableros visuales interactivos y automatizados que funcionen 24/7, garantizando que Juan disponga de un flujo constante de conocimiento procesable para liderar la toma de decisiones estratégicas de manera oportuna.